PROJETO FINAL · BIZ 5802 · IB-USP · 2026

Classificação de Diabetes por Meio de Redes Neurais Artificiais Multilayer Perceptron

Uma MLP treinada com 21 indicadores de saúde autorrelatados (BRFSS 2015) consegue identificar pessoas com diabetes e superar uma regressão logística?

Grupo 4
Aline Muniz · Dandara Cidade · Fernando Pablo
Gabriela Santos · Ligia Assis

Modelagem de Dados com Redes Neurais Artificiais
PPG em Zoologia · Instituto de Biociências · USP
Prof. Dr. Welton Dionisio da Silva

RESULTADOS NO CONJUNTO DE TESTE

0,830
ROC-AUC da MLP (regressão logística: 0,822)

81,5%
sensibilidade com o limiar de Youden (0,495)

0,097
escore de Brier das probabilidades corrigidas

57%
dos casos de diabetes estão nos 20% de maior risco previsto

PRINCIPAIS ACHADOS

- A MLP superou a regressão logística em todas as métricas independentes do limiar, mas por margens pequenas (+0,008 de ROC-AUC e +0,032 de PR-AUC).
- Sem regularização, a rede terminou pior do que o modelo linear (ROC-AUC de 0,774); o Early Stopping respondeu pela maior parte do ganho.
- Saúde geral, IMC, idade, pressão alta e colesterol alto concentram quase toda a informação usada pelo modelo.
- O modelo erra sobretudo pessoas com diabetes que não apresentam o perfil clássico de risco, e discrimina pior dentro dos grupos de maior risco.

Sumário

1 Introdução 3

2 Metodologia 5

2.1 Base de dados e ambiente computacional 5

2.2 Análise exploratória dos dados 7

2.3 Preparação dos dados 11

2.4 Desenvolvimento das redes neurais 11

2.5 Ajuste, regularização e avaliação 12

3 Resultados 15

3.1 Conjunto de dados após o pré-processamento 15

3.2 Busca de hiperparâmetros 15

3.3 Desempenho do modelo selecionado 19

3.4 Distribuição dos resíduos 22

3.5 Interpretabilidade do modelo 24

4 Conclusão 27

Referências 29

Apêndice A – Diagrama da arquitetura da rede neural 31

Código e reprodutibilidade. Todos os resultados vêm do notebook do projeto, executado no Google Colaboratory (CPU) com semente aleatória fixa (SEED = 42).

Notebook: colab.research.google.com/drive/19N6asSb6F0Zc29IUA71fz_7Fx0-bg0UU

Repositório: github.com/ligia-soares-ds/Projeto_Final_Diabetes_RNA

1 Introdução

O diabetes mellitus é uma doença metabólica crônica caracterizada pela elevação persistente da glicose no sangue e associada a complicações cardiovasculares, renais, neurológicas e oftalmológicas. De acordo com a 11ª edição do *IDF Diabetes Atlas* (2025), cerca de 589 milhões de adultos entre 20 e 79 anos viviam com diabetes em 2024, aproximadamente um em cada nove, e estima-se que 252 milhões deles, perto de 43%, não sabiam que tinham a doença (1). O diabetes tipo 2 responde por mais de 90% dos casos e está ligado a fatores modificáveis, como excesso de peso, sedentarismo e hipertensão; por isso, identificar precocemente pessoas em risco pode contribuir para prevenir ou retardar a doença e suas complicações (1).

Muitos dos fatores de risco conhecidos, como pressão alta, colesterol elevado, índice de massa corporal, atividade física, tabagismo, idade e estado de saúde geral, podem ser obtidos por questionário. Inquéritos populacionais de saúde coletam essas informações em larga escala e constituem uma base para a construção de instrumentos de rastreio de baixo custo. O *Behavioral Risk Factor Surveillance System* (BRFSS), conduzido desde 1984 pelos *Centers for Disease Control and Prevention* dos Estados Unidos, é um sistema contínuo de entrevistas telefônicas de saúde e coleta anualmente dados sobre comportamentos de risco, condições crônicas e o uso de serviços preventivos entre adultos (2).

O conjunto de dados utilizado neste trabalho, o *Diabetes Health Indicators Dataset* (3), disponibilizado no Kaggle, deriva do BRFSS de 2015 e reúne 253.680 respostas e 21 variáveis preditoras, que cobrem condições de saúde diagnosticadas, hábitos de vida, saúde e características sociodemográficas. A variável-alvo é binária e indica se o entrevistado relatou diagnóstico de diabetes. A regressão logística, modelo de referência para esse tipo de problema, soma a contribuição de cada variável separadamente e não capta, por padrão, o efeito conjunto de dois ou mais fatores de risco; essas interações só entram no modelo se forem adicionadas manualmente. Uma rede neural do tipo *Multilayer Perceptron* (MLP), com camadas ocultas e funções de ativação não lineares, aprende essas interações diretamente dos dados (4).

Estudos anteriores com dados tabulares de saúde, contudo, relatam desempenho próximo entre redes neurais e regressão logística (5). Isso levanta a dúvida sobre se as camadas ocultas de uma MLP acrescentam capacidade preditiva em dados dessa natureza ou se um modelo linear bem ajustado é suficiente.

> **Questão de pesquisa.** Uma rede neural MLP treinada com indicadores de saúde consegue identificar pessoas com diabetes, e seu desempenho supera o de uma regressão logística?

O objetivo geral foi desenvolver e avaliar uma MLP para estimar o risco de diabetes a partir dos indicadores do BRFSS 2015. Os objetivos específicos foram: i) caracterizar os dados e definir uma estratégia de preparação sem vazamento de informação entre os conjuntos de treinamento, validação e teste; ii) avaliar, por meio de um estudo de ablação, a contribuição das técnicas de regularização (Early Stopping, Dropout, L2 e Batch Normalization) e comparar diferentes otimizadores; iii) comparar, sob o mesmo protocolo de avaliação, o desempenho da MLP com o de uma regressão logística; e iv) interpretar o modelo final, analisando a importância das variáveis, a calibração das probabilidades, os erros e o desempenho em subgrupos.

O restante do relatório está organizado da seguinte forma: a seção 2 descreve a metodologia (preparação e exploração dos dados e desenvolvimento dos modelos); a seção 3 apresenta os resultados, incluindo os hiperparâmetros selecionados, o desempenho dos modelos e as métricas de erro; e a seção 4 conclui o relatório.

2 Metodologia

Os procedimentos estão descritos na ordem em que foram executados no notebook do projeto. Todas as etapas foram realizadas com semente aleatória fixa (SEED = 42) para garantir a reprodutibilidade.

2.1 Base de dados e ambiente computacional

Neste trabalho, foi utilizado o Google Colaboratory (7), em CPU, com Python 3.13.18. O conjunto de dados (*Diabetes Health Indicators Dataset*), disponibilizado na plataforma Kaggle, foi obtido com a função *kagglehub.dataset_download* (6) e lido com a biblioteca pandas (8) (função *read_csv*), com operações numéricas em NumPy (9). As versões utilizadas foram: TensorFlow/Keras 2.21.0, pandas 2.2.3, NumPy 2.4.6, scikit-learn 1.6.1, matplotlib 3.10.0 (10), seaborn 0.13.2 (11) e SHAP 0.54.1. A base contém informações provenientes do BRFSS (2), referentes ao ano de 2015, e reúne indicadores relacionados às condições de saúde, aos hábitos de vida e às características sociodemográficas da população investigada. O dataset é distribuído em três arquivos, descritos na Tabela 1. Todos possuem as mesmas 21 variáveis preditoras e diferem apenas na definição da variável-alvo e no balanceamento.

Tabela 1 – Arquivos que compõem o *Diabetes Health Indicators Dataset*

Arquivo	Variável-alvo	Observações	Distribuição do alvo
diabetes_012_health_indicators_BRFSS2015	0 = sem diabetes; 1 = pré-diabetes; 2 = diabetes	253.680	84,2% / 1,8% / 13,9%
diabetes_binary_health_indicators_BRFSS2015	**0 = sem diabetes ou pré-diabetes; 1 = diabetes**	**253.680**	**86,1% / 13,9%**
diabetes_binary_5050split_health_indicators_BRFSS2015	Igual ao anterior	70.692	50% / 50%

Fonte: elaborado pelos autores (2026), com base em Teboul (3). Em destaque, o arquivo utilizado.

O arquivo selecionado, *diabetes_binary_health_indicators_BRFSS2015.csv*, preserva a prevalência observada na população (13,9%) e contém 253.680 registros e 22 variáveis, sendo 21 explicativas e uma variável resposta, denominada *Diabetes_binary*. Essa variável apresenta duas categorias: 0, correspondente aos registros sem diabetes ou pré-diabetes relatados, e 1, correspondente aos registros com diagnóstico de diabetes relatado.

O valor preditivo de um instrumento de rastreio depende da prevalência da condição; se o modelo fosse treinado e avaliado no arquivo balanceado artificialmente (50/50), as métricas descreveriam uma população fictícia e a precisão seria superestimada. O arquivo de três classes foi descartado porque o pré-diabetes representa apenas 1,8% das observações. A comparação das proporções entre os arquivos mostrou que, na versão binária, o pré-diabetes foi agrupado com a ausência de diabetes (84,2% + 1,8% = 86,1%); portanto, o modelo prediz o diagnóstico autorrelatado de diabetes.

Entre as variáveis explicativas estão o índice de massa corporal (BMI), a presença de pressão arterial elevada (HighBP), o colesterol elevado (HighChol), o tabagismo (Smoker), a prática de atividade física (PhysActivity), a idade categorizada (Age), o nível de escolaridade (Education) e a renda (Income). A

Tabela 2 descreve as 21 variáveis preditoras, todas já codificadas numericamente: 14 binárias, quatro ordinais e três numéricas discretas.

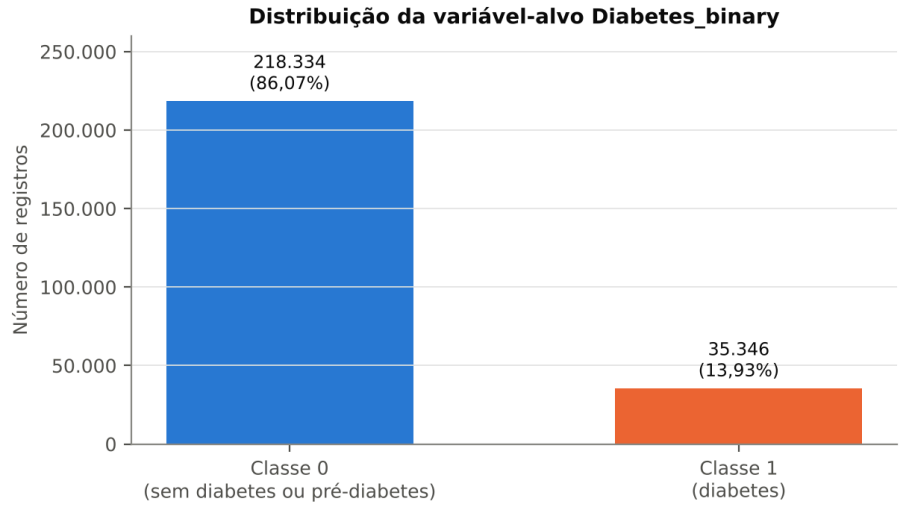
Tabela 2 – Variáveis preditoras do conjunto de dados

Variável	Descrição	Tipo
HighBP	Pressão alta diagnosticada	Binária
HighChol	Colesterol alto diagnosticado	Binária
CholCheck	Exame de colesterol nos últimos 5 anos	Binária
BMI	Índice de massa corporal (kg/m²)	Numérica
Smoker	Fumou ao menos 100 cigarros na vida	Binária
Stroke	Já teve acidente vascular cerebral	Binária
HeartDiseaseorAttack	Doença coronariana ou infarto	Binária
PhysActivity	Atividade física nos últimos 30 dias	Binária
Fruits / Veggies	Consumo diário de frutas / vegetais	Binárias
HvyAlcoholConsump	Consumo pesado de álcool	Binária
AnyHealthcare	Possui cobertura de saúde	Binária
NoDocbcCost	Deixou de ir ao médico por custo no último ano	Binária
GenHlth	Saúde geral autorrelatada (1 = excelente a 5 = ruim)	Ordinal
MentHlth / PhysHlth	Dias de saúde mental / física ruim nos últimos 30 dias	Numéricas (0–30)
DiffWalk	Dificuldade séria para caminhar ou subir escadas	Binária
Sex	Sexo (0 = feminino; 1 = masculino)	Binária
Age	Faixa etária em 13 categorias (1 = 18–24 a 13 = 80 ou mais)	Ordinal
Education	Escolaridade (1 a 6)	Ordinal
Income	Renda familiar (1 = menor a 8 = maior)	Ordinal

Fonte: elaborado pelos autores (2026), com base em Teboul (3) e CDC (2).

A análise inicial mostrou que todas as variáveis estavam armazenadas no formato numérico *float64*, incluindo indicadores binários e variáveis categóricas codificadas numericamente. Não foram identificados valores ausentes nas 22 colunas. A Figura 1 apresenta a distribuição da variável resposta, o que mostra um desbalanceamento entre as classes: dos 253.680 registros, 218.334 (86,07%) pertencem à classe 0, enquanto 35.346 (13,93%) pertencem à classe 1.

Figura 1 – Distribuição dos registros segundo a variável *Diabetes_binary*



Fonte: elaborado pelos autores (2026).

O problema foi definido como classificação binária, para a qual foi desenvolvida uma rede neural artificial do tipo MLP, com o objetivo de investigar a capacidade do modelo de identificar padrões associados às categorias da variável resposta a partir dos indicadores disponíveis.

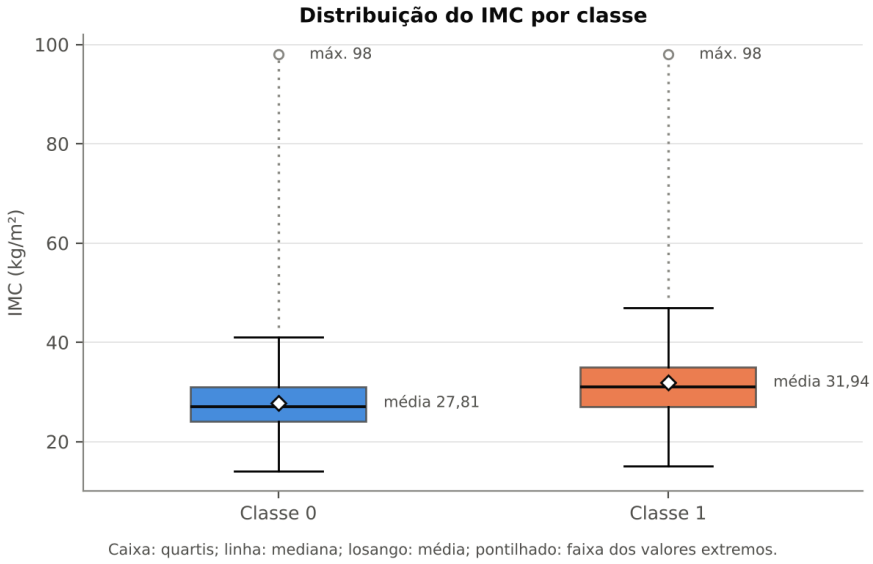
2.2 Análise exploratória dos dados

Inicialmente, realizou-se uma análise exploratória com o objetivo de examinar a estrutura e as características do conjunto de dados, identificar possíveis inconsistências e subsidiar as decisões de pré-processamento necessárias ao desenvolvimento da rede neural. Para isso, foram investigados os valores ausentes, os registros duplicados, as estatísticas descritivas e a distribuição das variáveis.

A verificação de valores ausentes, realizada por meio da função *isnull()* da biblioteca pandas, não identificou registros com valores nulos nas 22 variáveis analisadas; dessa forma, não foi necessário aplicar técnicas de imputação. Em relação à duplicidade, foram identificados 24.206 registros com combinações de valores repetidas, correspondentes a aproximadamente 9,54% do conjunto de dados. Entretanto, considerando que a base reúne informações provenientes de questionários de saúde e não apresenta identificadores individuais dos participantes, a ocorrência de registros idênticos não indica necessariamente duplicação indevida de observações; por esse motivo, eles não foram removidos.

A análise das estatísticas descritivas permitiu identificar diferentes características entre as variáveis. Enquanto parte delas apresenta respostas binárias, representadas pelos valores 0 e 1, outras correspondem a indicadores quantitativos ou categorias ordenadas. O Índice de Massa Corporal (IMC) apresentou média de 28,38, desvio-padrão de 6,61, mediana de 27 e valores entre 12 e 98. Para investigar a distribuição do IMC em relação à variável resposta, foi elaborado um gráfico de caixas, apresentado na Figura 2.

Figura 2 – Distribuição do IMC por classe

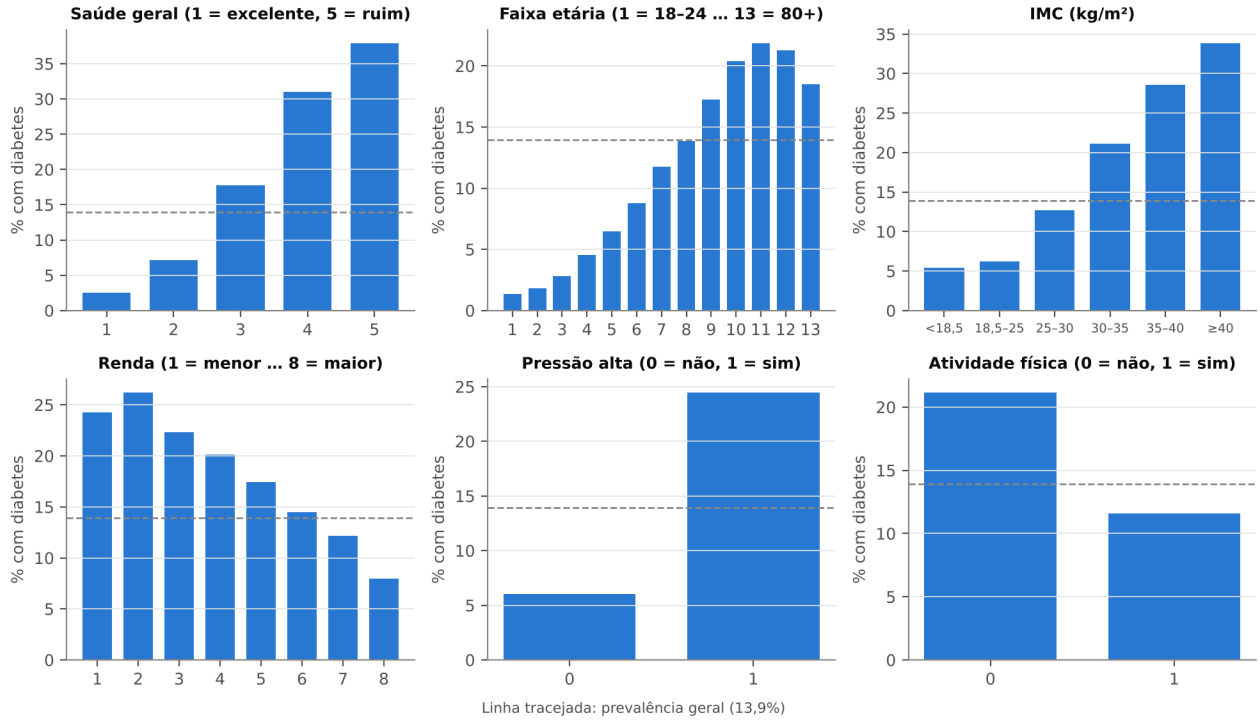


Fonte: elaborado pelos autores (2026), a partir das estatísticas descritivas do IMC por classe.

A Figura 2 mostra diferenças na distribuição do IMC entre as duas classes. Na classe 0, a média foi de 27,81, com mediana de 27 e desvio-padrão de 6,29. Na classe 1, observou-se média de 31,94, mediana de 31 e desvio-padrão de 7,36. Esses resultados indicam que os registros da categoria 1 apresentam, em geral, valores de IMC superiores aos da categoria 0. Há também valores discrepantes em ambas as classes, com observações que atingem IMC de 98; esses valores não foram considerados automaticamente incorretos, uma vez que podem corresponder a características reais dos indivíduos investigados. Assim, a análise exploratória identificou características relevantes para o desenvolvimento do modelo, especialmente o desbalanceamento da variável resposta, a existência de registros repetidos e a presença de valores extremos na distribuição do IMC.

A Figura 3 apresenta a prevalência de diabetes por categoria de seis variáveis. Observam-se gradientes claros de risco: a prevalência sobe de 2,5% entre quem relata saúde geral excelente para 37,9% entre quem relata saúde ruim, de 6,2% (IMC entre 18,5 e 25) para 33,8% (IMC ≥ 40) e de 6,0% para 24,4% entre pessoas com pressão alta. A renda e a atividade física apresentam associação inversa. Na idade, a prevalência cresce até 21,8% na faixa de 70 a 74 anos e cai para 18,5% na faixa de 80 anos ou mais, possivelmente por viés de sobrevivência.

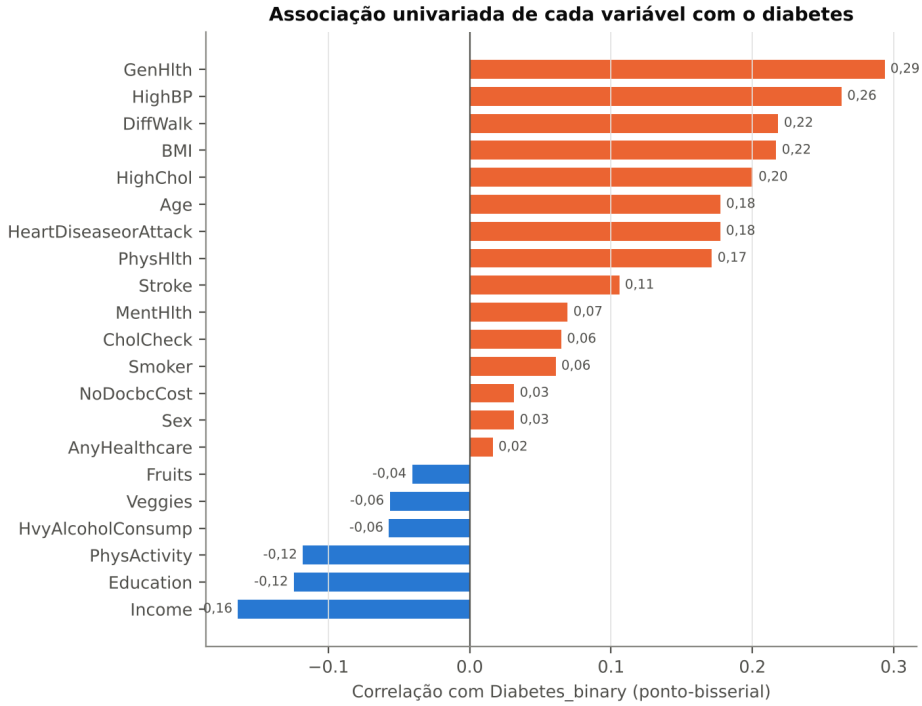
Figura 3 – Prevalência de diabetes por categoria das principais variáveis



Fonte: elaborado pelos autores (2026). A linha tracejada indica a prevalência geral (13,9%).

A Figura 4 mostra a correlação ponto-bisserial de cada variável com o alvo. As maiores associações foram com saúde geral (0,29), pressão alta (0,26), dificuldade para caminhar (0,22), IMC (0,22) e colesterol alto (0,20); renda (−0,16), escolaridade (−0,12) e atividade física (−0,12) apresentaram associação negativa. Como essas correlações são individualmente modestas, o desempenho depende da combinação das variáveis, o que reforça a escolha de um modelo capaz de aprender interações. Ressalta-se que o BRFSS é um estudo transversal e autorrelatado: variáveis como saúde geral ruim ou dificuldade para caminhar podem ser consequência do diabetes, e não causa.

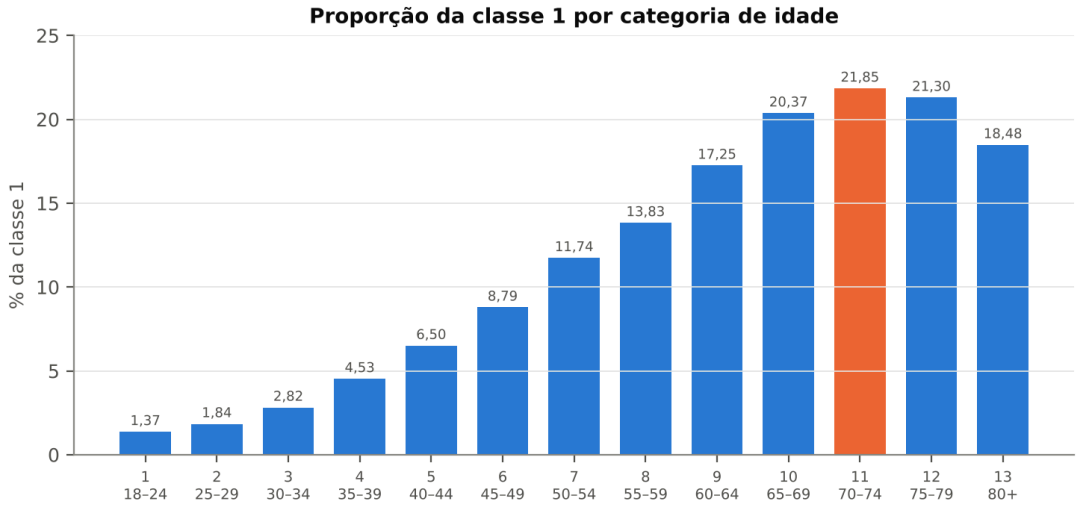
Figura 4 – Correlação de cada variável com o diagnóstico de diabetes



Fonte: elaborado pelos autores (2026).

Para investigar a relação entre a idade e a variável resposta, analisou-se a proporção de registros da classe 1 em cada categoria etária. A variável Age é representada por 13 categorias numéricas, de 18 anos até 80 anos ou mais (1 = 18 a 24 anos; 2 = 25 a 29 anos; e assim sucessivamente, em intervalos de cinco anos, até 13 = 80 anos ou mais), como mostra a Figura 5.

Figura 5 – Proporção da classe 1 por categoria de idade



Fonte: elaborado pelos autores (2026).

Observa-se um aumento progressivo da proporção de registros da classe 1 entre as categorias de idade 1 e 11, passando de 1,37% para 21,85%. A categoria 11 apresentou o maior percentual, seguida pelas categorias 12 e 10, com 21,30% e 20,37%, respectivamente. Na categoria 13, a proporção foi de 18,48%. Esses resultados sugerem uma associação entre as categorias etárias e a variável resposta,

indicando que a idade pode conter informações relevantes para a classificação. Entretanto, as diferenças observadas representam associações descritivas e não permitem estabelecer relações de causalidade.

2.3 Preparação dos dados

Após a análise exploratória, realizou-se a preparação do conjunto de dados para o desenvolvimento da MLP. Inicialmente, foram separadas as 21 variáveis explicativas da variável resposta *Diabetes_binary*. Como não havia valores ausentes, não foi necessária imputação. Os registros com combinações repetidas de respostas foram mantidos, uma vez que a base não apresenta identificadores individuais que permitam determinar se correspondem efetivamente a participantes duplicados. Da mesma forma, os valores extremos do IMC não foram removidos, evitando a exclusão de observações potencialmente válidas.

Para a modelagem, os dados foram divididos com a função *train_test_split* do scikit-learn (12) em treinamento (70%; 177.576 observações), validação (15%; 38.052) e teste (15%; 38.052), com estratificação pela variável-alvo e semente aleatória 42, de modo que as três partes mantiveram a prevalência de 13,93%. O conjunto de validação foi usado para comparar configurações e escolher o limiar de decisão, e o conjunto de teste foi utilizado uma única vez, na avaliação final.

As sete variáveis não binárias (BMI, GenHlth, MentHlth, PhysHlth, Age, Education e Income) foram padronizadas para média zero e desvio-padrão unitário com a classe *StandardScaler*, ajustada apenas no conjunto de treinamento e depois aplicada à validação e ao teste, evitando vazamento de informações. As variáveis binárias foram mantidas em 0/1.

Para lidar com o desbalanceamento, foram calculados pesos de classe inversamente proporcionais à frequência de cada classe com a função *compute_class_weight* (opção *balanced*), resultando em 0,581 para a classe negativa e 3,589 para a positiva. Com isso, o erro em um caso de diabetes passa a pesar cerca de 6,2 vezes mais na função de perda, sem descartar dados nem criar observações sintéticas.

2.4 Desenvolvimento das redes neurais

O diagnóstico de diabetes foi formulado como um problema de classificação binária: a partir das características de um indivíduo (como idade, hipertensão e colesterol elevado, entre outras), busca-se estimar a probabilidade de que ele tenha ou não a doença. O modelo de referência para esse tipo de problema é a regressão logística, que aplica a função sigmoide a uma combinação linear das variáveis preditoras. Ela foi usada como modelo-base para verificar se a MLP, por meio de camadas ocultas com ativações não lineares, captura interações entre as variáveis que o modelo linear não representa e, com isso, obtém desempenho superior. O modelo-base foi treinado com a classe *LogisticRegression* do scikit-learn (12), com *solver* lbfgs, penalização L2 com C = 1, *class_weight* = *balanced* e *max_iter* = 2000, sem ajuste de hiperparâmetros, com as mesmas partições e a mesma padronização da MLP.

A MLP foi implementada com o TensorFlow (13) e o Keras (14), por meio da API funcional. A rede (Apêndice A) recebe as 21 variáveis, passa por três camadas ocultas densas com 256, 128 e 64 neurônios e termina em um neurônio de saída, somando 46.849 parâmetros treináveis. O afunilamento (256, 128, 64) é uma disposição usual, em que as primeiras camadas combinam as variáveis de muitas

maneiras e as últimas condensam essas combinações na decisão final. Optou-se por uma rede com mais capacidade do que o necessário para 21 variáveis, para tornar observável o sobreajuste e medir a contribuição de cada técnica de regularização; arquiteturas menores não foram testadas.

As camadas ocultas utilizam a função de ativação ReLU (15), que é simples de calcular e não satura para valores positivos, atenuando o problema do desaparecimento do gradiente durante o *backpropagation*. O neurônio de saída usa a função sigmoide, que restringe o resultado ao intervalo entre 0 e 1 e permite interpretá-lo como probabilidade. Os pesos foram inicializados com o método de Glorot uniforme (16), padrão da camada Dense, com a mesma semente (42) fixada antes da construção de cada modelo, para que todos os experimentos partissem da mesma inicialização. A função de perda foi a entropia cruzada binária (*binary_crossentropy*), ponderada pelos pesos de classe.

O otimizador padrão foi o Adam (17), com taxa de aprendizado de 0,001, tamanho de lote (*batch size*) de 1.024 exemplos e no máximo 60 épocas, com parada antecipada descrita na seção 2.5; o modelo final treinou por 21 épocas e reteve os pesos da época 13. O lote relativamente grande foi escolhido porque o conjunto de treinamento é volumoso e o ambiente era CPU, o que reduz o tempo por época sem prejudicar a convergência observada nas curvas. Como a perda de treinamento é ponderada, os exemplos de validação também receberam pesos (argumento *validation_data* com *sample_weight*), para que as perdas de treinamento e de validação ficassem na mesma escala e as curvas pudessem ser comparadas. Durante o treinamento foram monitoradas a perda e a AUC (*keras.metrics.AUC*).

A seleção ocorreu em duas etapas, primeiro entre técnicas de regularização e depois entre otimizadores, sempre pelo mesmo critério; as configurações comparadas, seus parâmetros e resultados são apresentados na seção 2.5. O critério de seleção da configuração final foi o maior ROC-AUC no conjunto de validação. O ROC-AUC pode ser lido como a probabilidade de que, sorteando uma pessoa com diabetes e outra sem, o modelo atribua probabilidade maior à primeira. Esse critério foi adotado porque não depende do limiar de decisão e mede a capacidade de ordenar os indivíduos, que é o que importa em um instrumento de rastreio. O conjunto de teste não participou de nenhuma dessas decisões.

2.5 Ajuste, regularização e avaliação

Esta seção descreve como a configuração apresentada na seção 2.4 foi refinada e como o modelo resultante foi avaliado, na ordem em que as etapas foram executadas: estudo de ablação das técnicas de regularização, comparação de otimizadores, definição do limiar de decisão, métricas de avaliação e análise de interpretabilidade do modelo final.

Para avaliar a contribuição efetiva de cada estratégia, foi realizado um estudo de ablação em que a mesma arquitetura foi treinada alterando-se um fator de cada vez (Tabela 3), mantidos o otimizador Adam com taxa de 0,001, lote de 1.024, os pesos de classe e a semente aleatória. A configuração com maior ROC-AUC de validação foi selecionada para as etapas seguintes.

Tabela 3 – Delineamento dos experimentos de regularização

Exp.	Configuração	Finalidade
A	Sem regularização; 60 épocas fixas	Observar o sobreajuste sem controle
B	Early Stopping (paciência = 8)	Interromper o treino no ponto ótimo
C	B + Dropout (taxa = 0,3)	Reduzir a coadaptação entre neurônios
D	B + regularização L2 ($\lambda = 10^{-4}$)	Penalizar pesos de grande magnitude
E	B + Batch Normalization	Estabilizar e acelerar o treinamento
F	B + Dropout + L2 + Batch Normalization	Verificar se as técnicas se somam

Fonte: elaborado pelos autores (2026).

O Early Stopping (18), implementado com o *callback* *keras.callbacks.EarlyStopping*, monitora a perda de validação e interrompe o treinamento após oito épocas sem melhora, restaurando os pesos da melhor época (*restore_best_weights* = *True*). O Dropout (19) desliga aleatoriamente 30% dos neurônios de cada camada oculta a cada passo de treinamento, impedindo que a rede dependa de combinações específicas de neurônios. A regularização L2 (20) (*regularizers.l2*) acrescenta à perda uma penalidade proporcional ao quadrado dos pesos, favorecendo funções mais suaves. A Batch Normalization (21) normaliza as ativações de cada camada dentro do lote; quando utilizada, as camadas densas foram criadas sem viés (*use_bias* = *False*), pois a normalização já inclui um parâmetro de deslocamento.

Em seguida, mantendo a configuração C, foram comparados quatro otimizadores (*keras.optimizers*): (i) SGD com taxa de aprendizado de 0,01; (ii) SGD com Momentum de 0,9 e taxa de 0,01; (iii) RMSProp com taxa de 0,001; e (iv) Adam com taxa de 0,001 (17). As taxas maiores para o SGD seguem a prática usual, pois esse otimizador não adapta a taxa de aprendizado de cada parâmetro; em todos os casos, a taxa foi mantida constante, sem redução programada. Não foi realizada busca em grade ou aleatória, porque o objetivo foi isolar o efeito de cada técnica em comparações controladas.

Como as métricas dependem do limiar de decisão, este foi escolhido no conjunto de validação pelo índice de Youden (22), J = sensibilidade + especificidade − 1, que busca o melhor equilíbrio entre detectar os casos positivos e descartar corretamente os negativos. A avaliação utilizou as funções do módulo *sklearn.metrics* (12): ROC-AUC (*roc_auc_score*), PR-AUC (*average_precision_score*), matriz de confusão (*confusion_matrix*), acurácia, sensibilidade (revocação), especificidade, precisão e F1. A acurácia não foi usada como métrica principal porque um classificador que sempre prediz a ausência de diabetes acertaria 86% dos casos sem detectar nenhum positivo.

Para comparar com métricas de erro usuais em regressão, foram calculados sobre as probabilidades previstas a perda logarítmica, o erro absoluto médio (MAE), o erro quadrático médio, que neste contexto corresponde ao escore de Brier (23), sua raiz (RMSE), o R^2 na forma de *Brier skill score*, o pseudo-R^2 de McFadden (24) e o R^2 de Tjur (25). Como os pesos de classe deslocam as probabilidades previstas em direção à classe minoritária, essas métricas foram calculadas após a correção para a prevalência real, dividindo-se as chances (*odds*) previstas pela razão entre os pesos de classe ($w_1/w_0 \approx 6{,}2$), procedimento análogo à correção por informação a priori descrita por King e Zeng (26). Essa correção não altera a ordenação das observações e, portanto, não modifica ROC-AUC, PR-AUC nem o limiar.

Por fim, a interpretabilidade do modelo final foi avaliada pela importância por permutação (27), que mede a queda do ROC-AUC ao embaralhar cada variável no conjunto de teste (15.000 observações, cinco repetições), e pelos valores SHAP (28), calculados com a classe *PermutationExplainer* da biblioteca shap (100 observações de referência do treinamento, 400 explicadas do teste), que estimam a contribuição de cada variável e a direção do seu efeito em cada predição.

3 Resultados

3.1 Conjunto de dados após o pré-processamento

Ao final da preparação, o conjunto ficou dividido em 177.576 observações de treinamento, 38.052 de validação e 38.052 de teste, todas com prevalência de diabetes de 13,93%, o que confirma que a estratificação preservou a proporção entre as classes nas três partes. As sete variáveis não binárias passaram a ter média zero e desvio-padrão unitário no conjunto de treinamento, e as 14 variáveis binárias foram mantidas em 0/1, resultando em matrizes com 21 colunas para os três conjuntos.

Os pesos de classe calculados foram de 0,581 para a classe negativa e de 3,589 para a positiva. Na prática, cada pessoa com diabetes passou a pesar cerca de 6,2 vezes mais na função de perda, de modo que, somadas, as duas classes contribuem igualmente para o treinamento, sem que fosse preciso descartar dados ou criar observações sintéticas. Nenhuma observação foi removida: os 24.206 registros repetidos e os valores extremos de IMC foram mantidos, pelas razões discutidas na seção 2.2.

3.2 Busca de hiperparâmetros

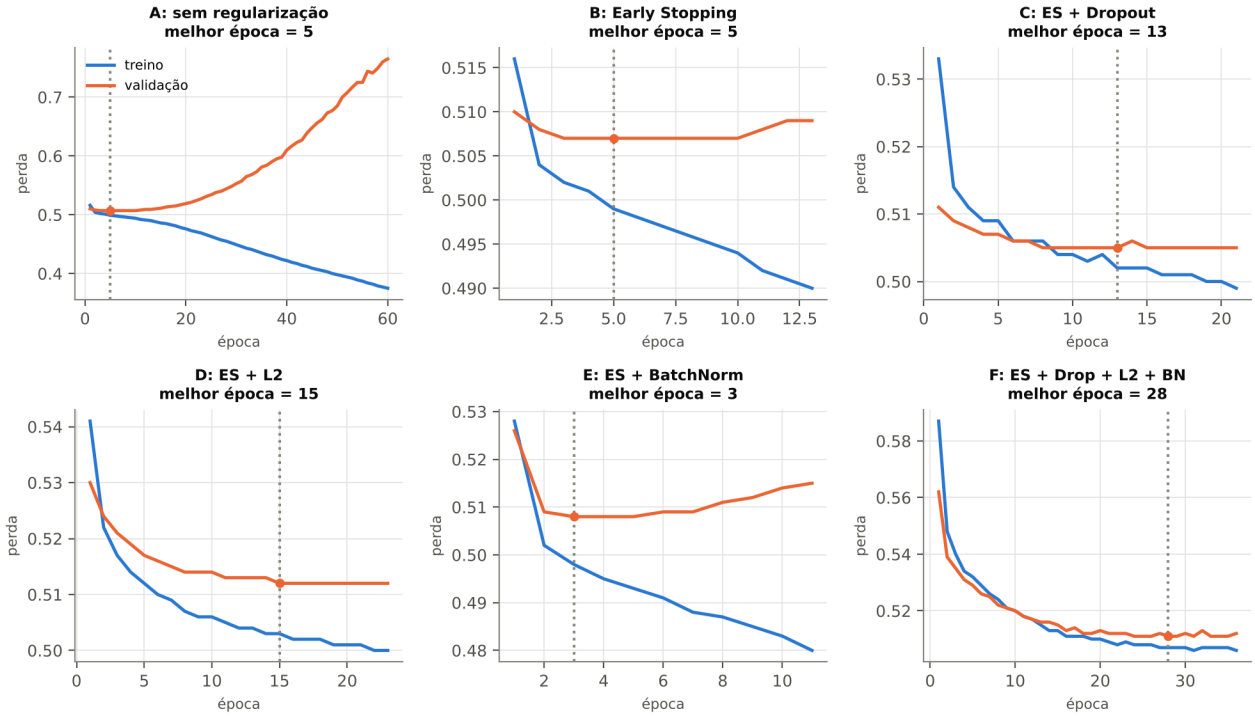
Antes de qualquer rede neural, a regressão logística estabeleceu a referência: ROC-AUC de 0,821 e PR-AUC de 0,402 na validação. Esse é um patamar alto para um modelo linear, o que já sinalizava que a MLP teria pouco espaço para ganhos expressivos. A Tabela 4 resume os seis experimentos de regularização, e a Figura 6 mostra o que aconteceu, época a época, em cada um deles.

Tabela 4 – Resultados dos experimentos de regularização no conjunto de validação

Experimento	ROC-AUC	PR-AUC	Épocas	Melhor época	Tempo (s)
Regressão logística	*0,821*	*0,402*	–	–	*1,8*
A: sem regularização	0,774	0,340	60	5	146
B: Early Stopping	0,827	0,424	13	5	33
C: B + Dropout	**0,829**	**0,429**	**21**	**13**	**80**
D: B + L2	0,828	0,426	23	15	58
E: B + Batch Normalization	0,826	0,422	11	3	48
F: B + Dropout + L2 + BN	0,829	0,429	36	28	198

Fonte: elaborado pelos autores (2026). Em destaque, a configuração selecionada. Os tempos referem-se a uma execução em CPU no Google Colaboratory e variam ligeiramente entre execuções; as métricas foram idênticas em execuções repetidas.

Figura 6 – Curvas de aprendizado (perda de treinamento e de validação) dos experimentos de regularização



Fonte: elaborado pelos autores (2026). A linha pontilhada indica a melhor época.

O experimento A mostra, de forma quase didática, o que é o sobreajuste. Nas primeiras cinco épocas, treinamento e validação melhoram juntos: a rede está aprendendo padrões que valem para qualquer pessoa. A partir daí, as curvas se separam. A perda de treinamento continua caindo, até 0,375 na 60ª época, enquanto a de validação sobe sem parar, de 0,507 para cerca de 0,77. A rede deixou de aprender o padrão geral e passou a memorizar as particularidades das 177 mil pessoas do treinamento. O resultado é revelador: com 46.849 parâmetros e nenhum controle, a MLP terminou pior do que a regressão logística (ROC-AUC de 0,774 contra 0,821). Mais capacidade, sozinha, não significou um modelo melhor.

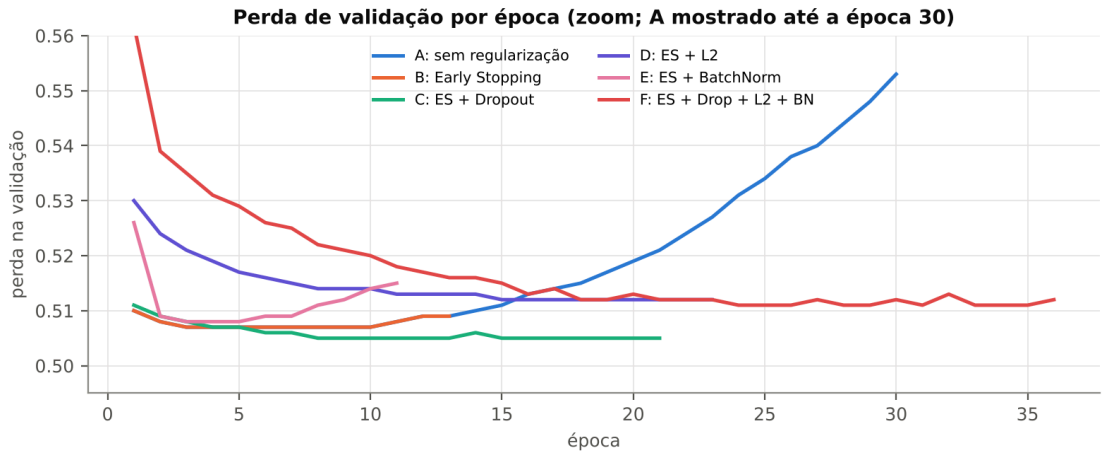
O Early Stopping (experimento B) resolveu a maior parte do problema com uma ideia simples: observar a validação e voltar para a melhor época. O ROC-AUC subiu para 0,827 (+0,053), e o treinamento ficou mais de quatro vezes mais curto. Foi, de longe, a intervenção de maior impacto. A melhor época, no entanto, continuou sendo a quinta, o que indica que o Early Stopping apenas interrompe o treino no momento certo, sem mudar a forma como a rede aprende.

O Dropout (experimento C) agiu de outra maneira. Ao desligar aleatoriamente 30% dos neurônios a cada passo, impediu que a rede se apoiasse em combinações específicas de neurônios, e o efeito aparece nas curvas como um adiamento do sobreajuste: a melhor época passou da 5ª para a 13ª. Com mais tempo de aprendizado útil, o modelo alcançou o maior ROC-AUC da ablação (0,829). Um detalhe da Figura 6 que poderia parecer um erro, mas não é: no início do treinamento, a perda de treinamento ficou acima da de validação. Isso acontece porque o Dropout só atua durante o treinamento; na validação, a rede trabalha com todos os neurônios ativos e, por isso, erra menos.

A regularização L2 (experimento D) produziu um efeito parecido com o do Dropout (0,828; melhor época 15), pois, ao penalizar pesos grandes, também suaviza a função aprendida. Já a Batch Normalization (experimento E) fez o que se espera dela, mas não o que precisávamos: a rede convergiu mais rápido (melhor época 3), porém sem ganho de discriminação (0,826). Faz sentido, porque a principal

finalidade dessa técnica é estabilizar e acelerar o treinamento, e não regularizar. Por fim, combinar todas as técnicas (experimento F) igualou o Dropout sozinho, mas exigiu 36 épocas e o maior tempo de treinamento entre os modelos regularizados. As técnicas não se somaram.

Figura 7 – Perda de validação dos seis experimentos na mesma escala



Fonte: elaborado pelos autores (2026). O experimento A é mostrado até a 30ª época.

A Figura 7 coloca todas as curvas de validação na mesma escala e resume a principal lição desta etapa: uma vez controlado o sobreajuste, todas as configurações chegam praticamente ao mesmo lugar. As diferenças entre C, D, E e F ficaram em até 0,003 de ROC-AUC, uma margem provavelmente menor do que a variação que observaríamos apenas trocando a semente aleatória. Em outras palavras, regularizar foi indispensável, mas a escolha da técnica específica teve pouca importância neste problema. Escolhemos a configuração C (Early Stopping + Dropout) por combinar o maior ROC-AUC com um custo computacional moderado.

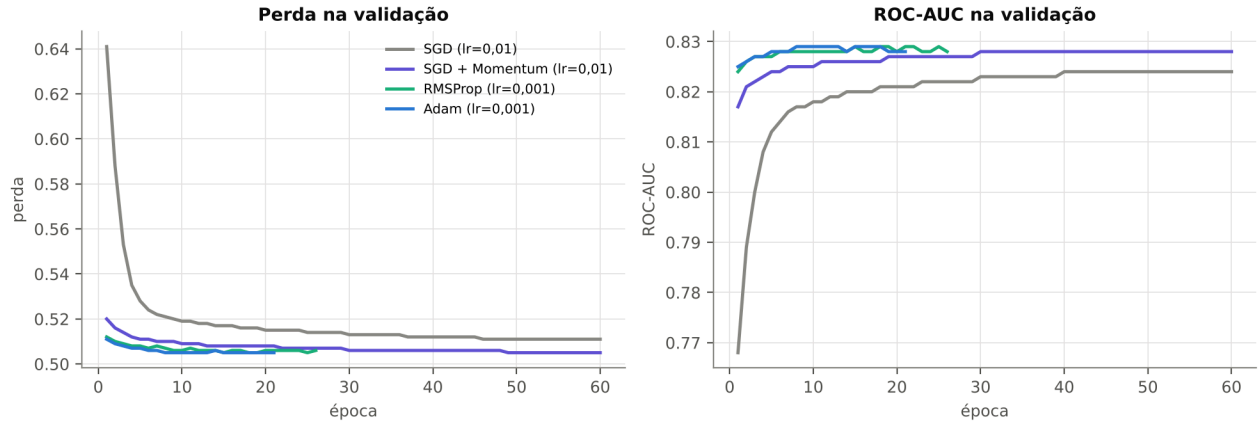
A comparação de otimizadores, feita com a configuração C, está na Tabela 5 e na Figura 8.

Tabela 5 – Comparação de otimizadores no conjunto de validação

Otimizador	Taxa de aprendizado	ROC-AUC	PR-AUC	Melhor época	Tempo (s)
SGD	0,01	0,824	0,419	60*	204
SGD + Momentum (0,9)	0,01	0,828	0,427	60*	220
RMSProp	0,001	0,829	0,429	18	111
Adam	**0,001**	**0,829**	**0,429**	**13**	**85**

Fonte: elaborado pelos autores (2026). * Atingiu o limite de 60 épocas com a perda de validação ainda em queda.

Figura 8 – Perda e ROC-AUC de validação por época para cada otimizador

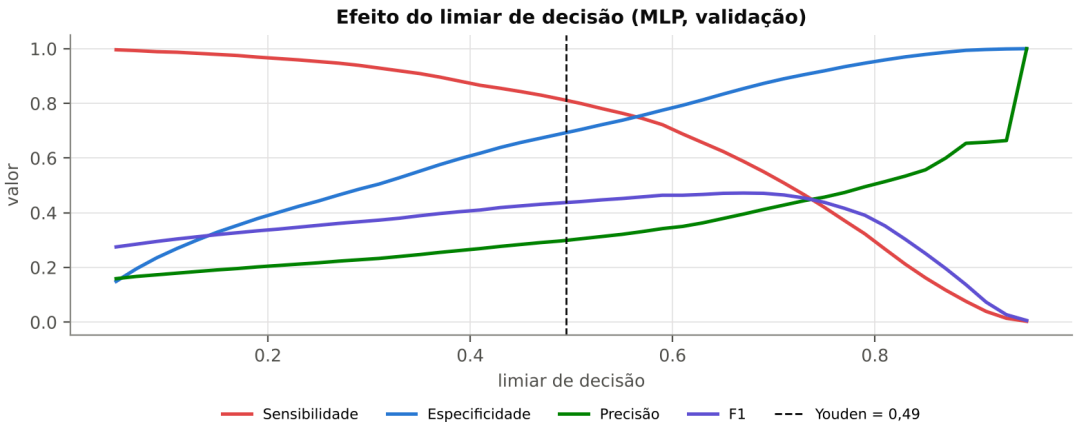


Fonte: elaborado pelos autores (2026).

O SGD puro avançou de forma lenta e constante e ainda estava melhorando quando o limite de 60 épocas foi atingido; não chegou a convergir. O Momentum, que acumula uma espécie de velocidade nas direções em que o gradiente aponta de forma consistente, acelerou bastante esse percurso (0,828 contra 0,824 no mesmo número de épocas), mas também não convergiu. RMSProp e Adam, que ajustam a taxa de aprendizado de cada peso individualmente, chegaram ao melhor resultado em 18 e 13 épocas, respectivamente. Na prática, os três otimizadores mais eficientes alcançaram o mesmo desempenho; a diferença esteve no caminho até lá, com o Adam gastando menos da metade do tempo do SGD. Por isso, o modelo final utilizou Adam. Vale destacar que essa escolha se justifica pela eficiência e pela estabilidade, e não por uma acurácia maior.

Toda classificação binária exige decidir a partir de que probabilidade uma pessoa será considerada positiva. A Figura 9 mostra esse compromisso no conjunto de validação: à medida que o limiar aumenta, a especificidade sobe e a sensibilidade cai. O índice de Youden indicou 0,495 para a MLP (e 0,469 para a regressão logística), muito próximo de 0,5. Isso não é coincidência: como os pesos de classe fazem o modelo aprender como se as duas classes tivessem o mesmo tamanho, o ponto de equilíbrio naturalmente se desloca para perto de 0,5.

Figura 9 – Efeito do limiar de decisão nas métricas da MLP (validação)



Fonte: elaborado pelos autores (2026).

O limiar, porém, é uma escolha que depende do contexto, assim como os pontos de corte de qualquer instrumento de rastreio. Se o custo de deixar passar um caso fosse considerado muito maior do que o de pedir um exame desnecessário, poderíamos reduzir o limiar para 0,35, por exemplo: a sensibilidade subiria para cerca de 91%, mas a especificidade cairia para 55% e a precisão para 25%. Mantivemos o critério de Youden por ser objetivo e equilibrado, mas essa flexibilidade é uma das vantagens práticas de um modelo que fornece probabilidades.

3.3 Desempenho do modelo selecionado

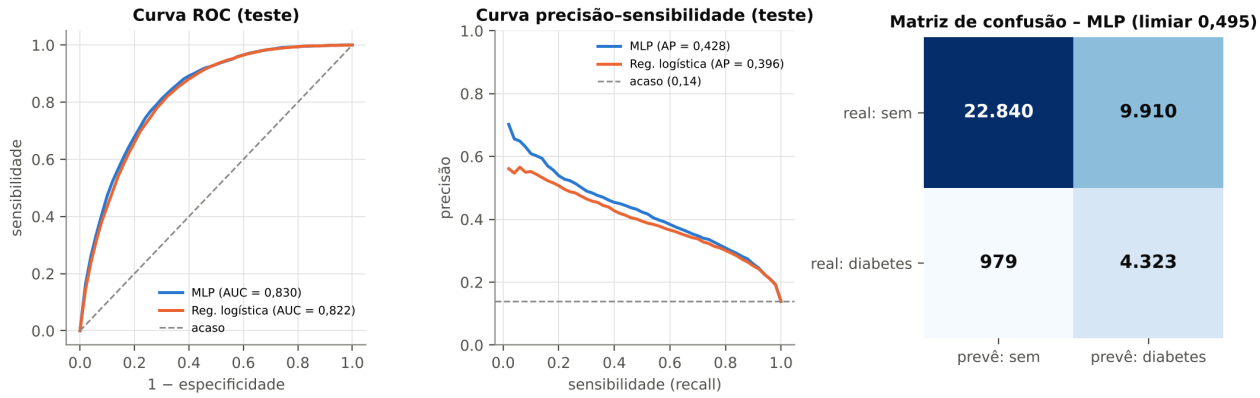
Com o modelo e o limiar definidos na validação, o conjunto de teste foi usado uma única vez. A Tabela 6 e a Figura 10 apresentam os resultados.

Tabela 6 – Desempenho dos modelos no conjunto de teste

Modelo (limiar)	ROC-AUC	PR-AUC	Acurácia	Sensib.	Especif.	Precisão	F1
Reg. logística (0,500)	*0,822*	*0,396*	*0,733*	*0,763*	*0,729*	*0,313*	*0,444*
Reg. logística (0,469)	*0,822*	*0,396*	*0,715*	*0,795*	*0,703*	*0,302*	*0,438*
MLP (0,500)	0,830	0,428	0,717	0,810	0,702	0,305	0,443
MLP (0,495)	**0,830**	**0,428**	**0,714**	**0,815**	**0,697**	**0,304**	**0,443**

Fonte: elaborado pelos autores (2026). Em destaque, o modelo final com o limiar de Youden.

Figura 10 – Curva ROC, curva precisão–sensibilidade e matriz de confusão da MLP no conjunto de teste



Fonte: elaborado pelos autores (2026).

O primeiro ponto a observar é a estabilidade: o ROC-AUC da MLP foi de 0,829 na validação e de 0,830 no teste. O modelo generaliza bem, e as escolhas feitas na validação não ficaram ajustadas demais àquele conjunto específico. Pela classificação usual de Hosmer, Lemeshow e Sturdivant (29), valores entre 0,8 e 0,9 correspondem a uma discriminação excelente. O PR-AUC de 0,428, embora pareça modesto, é cerca de três vezes o valor esperado ao acaso (0,14).

A MLP superou a regressão logística em todas as métricas independentes do limiar, mas por margens pequenas: +0,008 de ROC-AUC e +0,032 de PR-AUC. A curva precisão–sensibilidade ajuda a entender onde está essa vantagem: as duas curvas quase coincidem na maior parte do trajeto, e a MLP se destaca na região de baixa sensibilidade, ou seja, entre as pessoas com maior risco previsto. A rede parece aproveitar combinações de fatores para identificar com mais segurança os casos mais evidentes, mas não muda substancialmente o quadro geral.

A matriz de confusão traduz esses números em pessoas. Das 5.302 pessoas com diabetes no teste, o modelo identificou 4.323 (81,5%) e deixou passar 979. Por outro lado, apontou 9.910 pessoas sem diabetes como positivas, o que significa cerca de 2,3 alarmes falsos para cada caso verdadeiro.

> **Em mil pessoas.** Imaginemos o modelo aplicado a mil pessoas com a mesma prevalência da amostra: das 139 com diabetes, cerca de 113 seriam encaminhadas para exame e 26 passariam despercebidas; ao mesmo tempo, cerca de 261 pessoas sem diabetes também seriam encaminhadas. No total, 374 pessoas fariam um exame confirmatório para que 113 casos fossem encontrados.

Esse é um perfil razoável para a primeira etapa de um rastreio, em que o exame seguinte, como a glicemia de jejum ou a hemoglobina glicada, é barato e pouco invasivo, mas não seria aceitável para um diagnóstico. Vale também notar a acurácia de 71,4%, inferior aos 86% que um classificador que sempre responde "sem diabetes" obteria. Esse contraste mostra, na prática, por que a acurácia não serve como métrica principal em dados desbalanceados: o modelo menos útil seria o mais "acurado".

Em comparação com a literatura, Xie et al. (5) obtiveram AUC de 0,795 e sensibilidade de 37,8% com uma rede neural no BRFSS de 2014. Nossos resultados são semelhantes ou ligeiramente superiores em discriminação e bem superiores em sensibilidade, embora a comparação deva ser feita com cautela, pois as bases, as variáveis e a definição do alvo diferem, e a sensibilidade depende do limiar escolhido. Há, contudo, um padrão comum aos dois estudos que nos parece o achado mais importante: rede neural e regressão logística chegam praticamente ao mesmo lugar. Isso sugere que o teto de desempenho é determinado sobretudo pela informação contida em dados autorrelatados, e não pela arquitetura do modelo.

A Tabela 7 reúne as métricas de perda e de erro calculadas sobre as probabilidades previstas.

Tabela 7 – Métricas de perda e de erro no conjunto de teste

Métrica	MLP	Regressão logística	Referência (prevalência)
Perda de entropia cruzada ponderada	0,502	–	–
Perda logarítmica (probabilidades corrigidas)	0,312	0,322	0,404
MAE	0,194	0,195	0,240
MSE (escore de Brier)	0,097	0,100	0,120
RMSE	0,311	0,317	0,346
R^2 (*Brier skill score*)	0,192	0,164	0
Pseudo-R^2 de McFadden	0,226	0,203	0
R^2 de Tjur	0,188	0,193	0

Fonte: elaborado pelos autores (2026). Exceto a primeira linha, as métricas usam probabilidades corrigidas para a prevalência real; a referência atribui a todos a prevalência do treinamento.

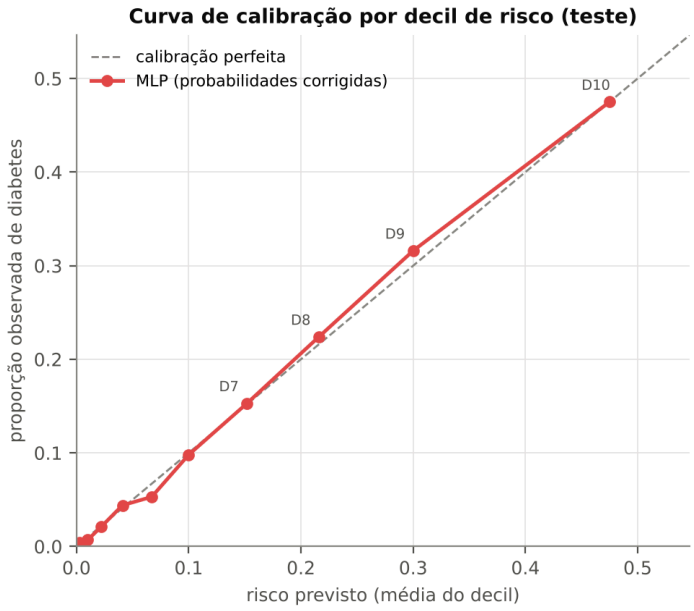
A perda ponderada no teste (0,502) ficou próxima do mínimo da validação (0,505), mais uma confirmação de que não houve sobreajuste. Depois da correção das probabilidades, a MLP apresentou erros menores do que a regressão logística e do que a referência em todas as métricas de perda, com

escore de Brier de 0,097, R^2 (*Brier skill score*) de 0,192 e pseudo-R^2 de McFadden de 0,226. O R^2 de Tjur, por sua vez, foi praticamente igual entre os dois modelos (0,188 e 0,193), o que reforça que a vantagem da rede é pequena.

Dois cuidados são importantes na leitura dessa tabela. O primeiro é que, sem a correção, as probabilidades infladas pelos pesos de classe produziriam escore de Brier de 0,178 e R^2 negativo (−0,48), embora o modelo discriminasse exatamente da mesma forma: o problema era de escala, e não de qualidade. O segundo é que, com um alvo binário, o R^2 tem um teto natural bem abaixo de 1, porque o modelo responde com probabilidades enquanto a realidade é sempre 0 ou 1. Por isso, esses valores não devem ser comparados com os R^2 típicos de problemas de regressão.

Para um instrumento de rastreio, não basta ordenar bem as pessoas; é desejável que a probabilidade informada corresponda ao risco real. A Figura 11 compara, em cada decil de risco, a probabilidade média prevista (já corrigida para a prevalência real) com a proporção observada de diabetes.

Figura 11 – Curva de calibração das probabilidades corrigidas por decil de risco (teste)



Fonte: elaborado pelos autores (2026).

Os pontos ficam praticamente sobre a diagonal em todos os decis. No decil de maior risco, por exemplo, a probabilidade média prevista foi de 47,5%, exatamente a proporção de pessoas com diabetes observada nesse grupo. Isso mostra que a correção pela razão entre os pesos de classe foi suficiente para recuperar probabilidades bem calibradas, sem precisar de um método adicional de calibração. Além disso, o risco está fortemente concentrado: os 10% de pessoas com maior risco previsto reúnem 34% de todos os casos de diabetes, os 20% de maior risco reúnem 57% e os 30% de maior risco, 73%. Para um programa de rastreio com recursos limitados, essa ordenação permitiria priorizar quem deve ser avaliado primeiro.

Por fim, um modelo pode ter bom desempenho global e, ainda assim, funcionar de forma desigual entre grupos. A Tabela 8 apresenta as métricas da MLP separadas por sexo, faixa etária, IMC e saúde geral, sempre com o mesmo limiar.

Tabela 8 – Desempenho da MLP por subgrupo no conjunto de teste (limiar de 0,495)

Subgrupo	n	Prevalência	ROC-AUC	Sensibilidade	Especificidade	Precisão
Feminino	21.321	13,0%	0,843	0,798	0,734	0,310
Masculino	16.731	15,1%	0,813	0,835	0,650	0,298
18–44 anos	8.382	4,4%	0,868	0,469	0,945	0,282
45–64 anos	16.327	13,6%	0,830	0,803	0,718	0,310
65 anos ou mais	13.343	20,3%	0,764	0,872	0,483	0,301
IMC < 25	10.874	5,5%	0,842	0,536	0,891	0,222
IMC 25–29,9	14.046	11,6%	0,808	0,753	0,721	0,262
IMC ≥ 30	13.132	23,4%	0,778	0,902	0,470	0,343
Saúde excelente/muito boa	20.123	5,6%	0,822	0,493	0,891	0,211
Saúde boa	11.411	17,7%	0,750	0,841	0,512	0,271
Saúde regular/ruim	6.518	33,0%	0,723	0,959	0,253	0,388

Fonte: elaborado pelos autores (2026).

Dois padrões chamam a atenção. O primeiro é que a discriminação diminui dentro dos grupos de maior risco: o ROC-AUC cai de 0,868 entre pessoas de 18 a 44 anos para 0,764 entre as de 65 anos ou mais, de 0,842 entre pessoas com IMC abaixo de 25 para 0,778 entre pessoas com obesidade, e de 0,822 para 0,723 entre quem relata saúde excelente e quem relata saúde regular ou ruim. A explicação é intuitiva: quando quase todos em um grupo compartilham os mesmos fatores de risco, essas variáveis deixam de ajudar a diferenciar quem tem a doença. O modelo também discriminou um pouco melhor as mulheres (0,843) do que os homens (0,813).

O segundo padrão diz respeito ao limiar único. Como a probabilidade prevista acompanha o perfil de risco, o mesmo limiar produz comportamentos muito diferentes entre os grupos: entre os jovens e as pessoas com IMC normal, a sensibilidade fica abaixo de 55%, enquanto entre os idosos e as pessoas com obesidade passa de 87%, com especificidade abaixo de 50%. Em um uso real, isso significaria deixar passar boa parte dos casos nos grupos de baixo risco e encaminhar para exame a maioria das pessoas dos grupos de alto risco. Limiares ajustados por grupo ou modelos específicos para subpopulações seriam caminhos possíveis, desde que discutidos também sob a ótica da equidade.

3.4 Distribuição dos resíduos

Em um problema de classificação, o equivalente aos resíduos é a diferença entre o que aconteceu (ter ou não diabetes) e o que o modelo previu. Em vez de olhar apenas quanto o modelo erra, esta seção investiga quem ele erra e por quê. Para isso, comparamos o perfil médio das pessoas em cada célula da matriz de confusão (Tabela 9).

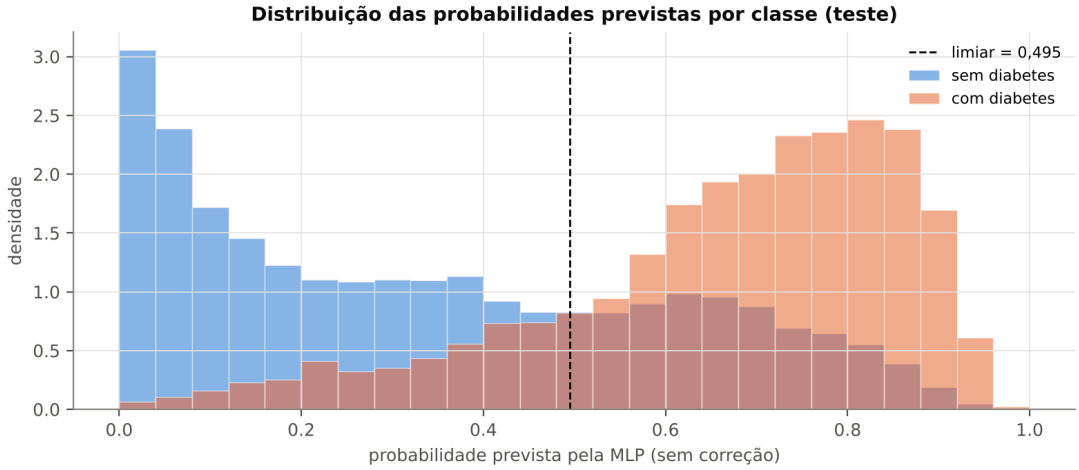
Tabela 9 – Perfil médio das pessoas em cada célula da matriz de confusão (teste)

Grupo	n	Prob.	Saúde geral	IMC	Idade	Pressão alta	Colest. alto	Dif. andar	Ativ. física	Renda
VP: diabetes detectado	4.323	0,74	3,49	32,9	9,6	84%	72%	42%	60%	5,0
FN: diabetes não detectado	**979**	**0,33**	**2,40**	**27,9**	**8,2**	**36%**	**42%**	**11%**	**78%**	**6,3**
FP: alarme falso	9.910	0,67	3,19	31,1	9,7	76%	65%	32%	65%	5,3
VN: sem diabetes, correto	22.840	0,19	2,03	26,4	7,0	21%	27%	6%	83%	6,6

Fonte: elaborado pelos autores (2026). Dif. andar = dificuldade para caminhar. Valores médios nas escalas originais: saúde geral de 1 (excelente) a 5 (ruim), idade em 13 faixas e renda em 8 faixas; para as variáveis binárias, a porcentagem indica a proporção de pessoas com a característica.

O padrão é claro e, de certa forma, esperado. As pessoas com diabetes que o modelo não detectou (falsos negativos) são aquelas que não se parecem com o perfil típico da doença: comparadas às detectadas, relatam saúde geral melhor (2,4 contra 3,5), têm IMC menor (27,9 contra 32,9), são mais jovens, têm muito menos pressão alta (36% contra 84%) e colesterol alto (42% contra 72%), praticam mais atividade física e têm renda maior. O modelo erra justamente quando os sinais de risco que ele conhece estão ausentes. Os falsos positivos são o espelho dessa situação: pessoas sem diabetes, mas com perfil de risco muito semelhante ao de quem tem a doença (IMC médio de 31,1, 76% com pressão alta e idade semelhante à dos verdadeiros positivos). Do ponto de vista da saúde pública, esse não é um erro grave, pois muitas dessas pessoas têm alto risco de desenvolver diabetes e se beneficiariam do acompanhamento.

Figura 12 – Distribuição das probabilidades previstas pela MLP para pessoas com e sem diabetes (teste)



Fonte: elaborado pelos autores (2026).

A Figura 12 mostra a mesma ideia de outro ângulo: as distribuições de probabilidade das duas classes se sobrepõem em uma faixa ampla. Há muitas pessoas sem diabetes com probabilidades altas e algumas pessoas com diabetes com probabilidades baixas, o que explica por que nenhum limiar consegue separar as classes de forma limpa. Os exemplos da Tabela 10 tornam essa sobreposição mais palpável.

Tabela 10 – Exemplos de previsões individuais no conjunto de teste

Caso	Real	Prob. corr.	Saúde geral	IMC	Faixa etária	Pressão alta	Colest. alto	Dif. andar	Doença card.	Exame colest.
VP com maior probabilidade	Sim	0,853	5	48	65–69	Sim	Sim	Sim	Sim	Sim
VP próximo do limiar	Sim	0,137	3	30	50–54	Não	Sim	Não	Não	Sim
FN com menor probabilidade	**Sim**	**0,002**	**1**	**20**	**25–29**	**Não**	**Não**	**Não**	**Não**	**Sim**
FP com maior probabilidade	Não	0,817	5	64	75–79	Sim	Sim	Sim	Sim	Sim
VN com menor probabilidade	Não	0,000	1	19	35–39	Não	Não	Não	Não	Não

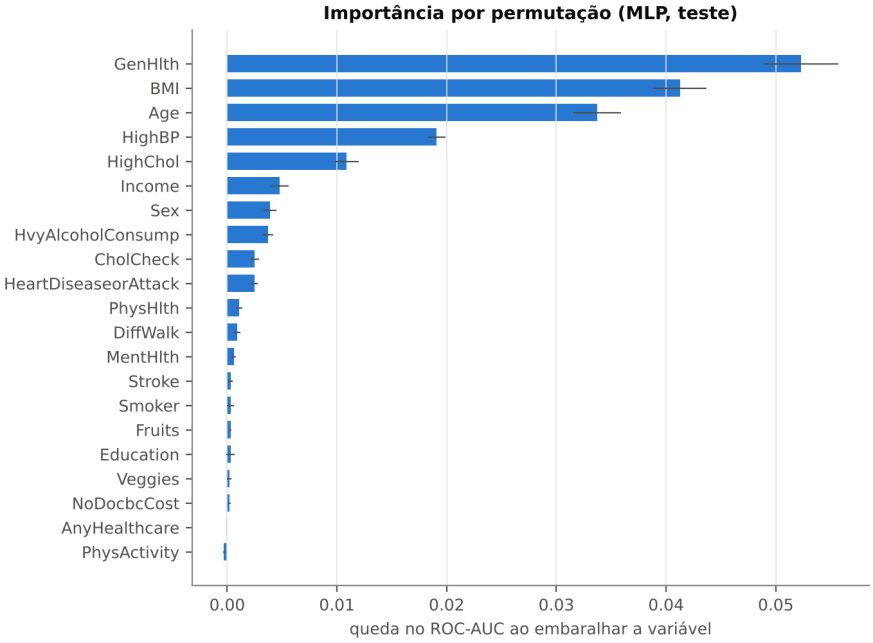
Fonte: elaborado pelos autores (2026). Probabilidade corrigida para a prevalência real; o caso "próximo do limiar" tem probabilidade sem correção de 0,495.

O falso negativo mais extremo é uma pessoa de 25 a 29 anos, com IMC de 20, saúde geral excelente e nenhum dos fatores de risco avaliados, mas que tem diabetes. Para o modelo, ela é indistinguível de qualquer jovem saudável, e possivelmente se trata de um caso de diabetes tipo 1, que não depende dos fatores de estilo de vida presentes na base. No extremo oposto, o falso positivo com maior probabilidade reúne praticamente todos os fatores de risco (IMC de 64, 75 a 79 anos, pressão e colesterol altos, doença cardíaca e dificuldade para caminhar) e, ainda assim, não relatou diagnóstico de diabetes, o que pode corresponder a um caso ainda não diagnosticado. Já a pessoa com a menor probabilidade de todas nunca fez exame de colesterol, detalhe que retomaremos a seguir.

3.5 Interpretabilidade do modelo

A Figura 13 apresenta a importância por permutação. Embaralhar a saúde geral reduziu o ROC-AUC em 0,052, o IMC em 0,041 e a idade em 0,034, seguidos de pressão alta (0,019) e colesterol alto (0,011); todas as demais variáveis contribuíram com menos de 0,005 cada. Em outras palavras, cinco variáveis concentram quase toda a informação usada pelo modelo, e são justamente as mesmas que distinguiram os falsos negativos dos verdadeiros positivos na Tabela 9. Esse resultado também é coerente com a análise exploratória e com os fatores de risco conhecidos para o diabetes tipo 2 (1).

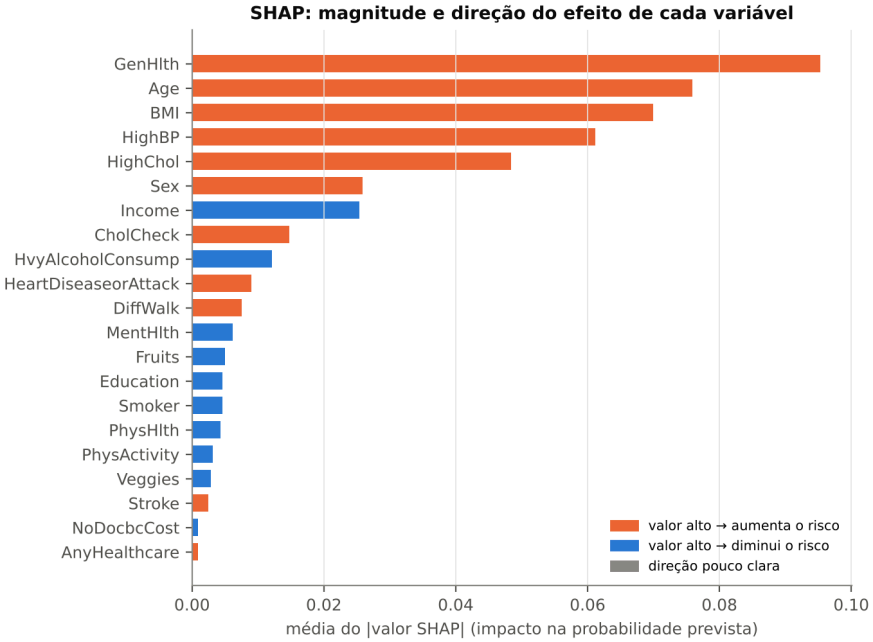
Figura 13 – Importância por permutação das variáveis no modelo final



Fonte: elaborado pelos autores (2026). Média de cinco repetições; as barras de erro indicam o desvio-padrão.

Os valores SHAP (Figura 14) acrescentam a direção dos efeitos. Pior saúde geral autorrelatada, mais idade e IMC mais alto aumentam a probabilidade prevista, assim como ter pressão alta, colesterol alto, doença cardíaca ou dificuldade para caminhar, enquanto uma renda maior a diminui. Até aqui, nada de surpreendente. Dois resultados, porém, merecem atenção, porque mostram o modelo aprendendo algo diferente do que se poderia supor.

Figura 14 – Magnitude e direção do efeito das variáveis segundo os valores SHAP



Fonte: elaborado pelos autores (2026). A cor indica o sinal da correlação entre o valor da variável e sua contribuição SHAP.

O primeiro é que não ter feito exame de colesterol nos últimos cinco anos diminui o risco previsto, como no caso de menor probabilidade da Tabela 10. Não há razão biológica para isso; a explicação mais provável é um viés de detecção, já que pessoas com menos contato com serviços de saúde têm menos chance de ter recebido o diagnóstico de diabetes. O segundo é que o consumo pesado de álcool também diminui o risco previsto. Isso não indica um efeito protetor do álcool, mas, provavelmente, causalidade reversa: pessoas já diagnosticadas costumam ser orientadas a reduzir o consumo. Esses dois achados lembram que o modelo aprende as associações presentes nos dados, inclusive as produzidas pela forma como os dados foram coletados, e não as relações causais da doença.

4 Conclusão

Voltando à pergunta que orientou este trabalho, a resposta é sim, com uma ressalva importante. A rede MLP treinada com 21 indicadores de saúde autorrelatados identificou pessoas com diabetes com desempenho adequado para a primeira etapa de um rastreio populacional: ROC-AUC de 0,830, sensibilidade de 81,5% e probabilidades bem calibradas após a correção para a prevalência real. A ressalva é que a vantagem sobre a regressão logística existiu, mas foi pequena. Esse resultado, que também aparece na literatura, nos parece tão informativo quanto o desempenho em si: em dados tabulares cujas relações são predominantemente aditivas e cuja informação é limitada pelo autorrelato, uma rede neural não cria conhecimento que não está nas variáveis. Ela aproveita um pouco melhor as combinações entre fatores, sobretudo entre as pessoas de maior risco, mas o teto de desempenho é dado pelos dados.

Sobre a rede neural, a principal lição veio dos experimentos de regularização. Uma rede com mais capacidade do que o problema exigia, treinada sem controle, terminou pior do que um modelo linear; foi preciso regularizá-la para que essa capacidade se tornasse útil. O Early Stopping respondeu pela maior parte do ganho, o Dropout e a regularização L2 permitiram que a rede aprendesse por mais tempo antes de sobreajustar, e a Batch Normalization acelerou a convergência sem melhorar a discriminação. Combinar todas as técnicas não trouxe benefício adicional. Entre os otimizadores, Adam e RMSProp chegaram ao mesmo resultado que o SGD com Momentum em uma fração das épocas. Em conjunto, essas comparações mostram que entender o que cada técnica faz foi mais importante do que acumular técnicas.

Sobre os dados, aprendemos que saúde geral autorrelatada, IMC, idade, pressão alta e colesterol concentram quase toda a informação preditiva, e que o modelo funciona melhor justamente onde esses sinais variam: ele erra, principalmente, pessoas com diabetes que não apresentam o perfil clássico de risco, e discrimina pior dentro dos grupos de maior risco, como idosos e pessoas com obesidade. A interpretabilidade revelou ainda que parte do que o modelo aprendeu reflete a forma como os dados foram produzidos, como no viés de detecção associado à ausência de exames de colesterol e na provável causalidade reversa do consumo de álcool.

Essas observações delimitam também as limitações do trabalho. Os dados são transversais e autorrelatados; o alvo representa o diagnóstico informado pelo entrevistado, sujeito a subdiagnóstico, e as associações encontradas não podem ser interpretadas como causais. A amostra refere-se aos Estados Unidos em 2015, de modo que a generalização para outras populações, como a brasileira, precisaria ser verificada com dados locais, por exemplo de inquéritos como a Pesquisa Nacional de Saúde. O desempenho desigual entre subgrupos indica que um limiar único pode ser inadequado em aplicações reais e que questões de equidade precisariam ser consideradas. Por fim, os experimentos foram realizados com uma única semente aleatória e com um único valor para a taxa de Dropout, o λ e a taxa de aprendizado, o que não permite afirmar se as pequenas diferenças entre as configurações regularizadas são reais.

Como próximos passos, sugerimos repetir os experimentos com múltiplas sementes ou validação cruzada, realizar uma busca sistemática de hiperparâmetros, comparar a MLP com modelos baseados em árvores, como o *gradient boosting*, avaliar limiares específicos por subgrupo e investigar o problema de três classes, incluindo o pré-diabetes, com técnicas voltadas a classes raras. Mais do

que buscar alguns décimos a mais de AUC, porém, o maior ganho provavelmente viria de incorporar informações ausentes da base, como histórico familiar e medidas laboratoriais simples, que permitiriam ao modelo enxergar justamente os casos que hoje ele não consegue identificar.

Referências

1. INTERNATIONAL DIABETES FEDERATION. **IDF Diabetes Atlas**. 11. ed. Brussels: International Diabetes Federation, 2025. Disponível em: https://diabetesatlas.org. Acesso em: 7 nov. 2026.
2. CENTERS FOR DISEASE CONTROL AND PREVENTION. **Behavioral Risk Factor Surveillance System**: overview: BRFSS 2015. Atlanta: CDC, 2016. Disponível em: https://www.cdc.gov/brfss/annual_data/2015/pdf/overview_2015.pdf. Acesso em: 7 nov. 2026.
3. TEBOUL, A. **Diabetes Health Indicators Dataset**. [S. l.]: Kaggle, 2021. Disponível em: https://www.kaggle.com/datasets/alexteboul/diabetes-health-indicators-dataset. Acesso em: 6 nov. 2026.
4. JAMES, G.; WITTEN, D.; HASTIE, T.; TIBSHIRANI, R.; TAYLOR, J. **An introduction to statistical learning**: with applications in Python. Cham: Springer, 2023. DOI: 10.1007/978-3-031-38747-0.
5. XIE, Z.; NIKOLAYEVA, O.; LUO, J.; LI, D. Building risk prediction models for type 2 diabetes using machine learning techniques. **Preventing Chronic Disease**, Atlanta, v. 16, e130, 2019. DOI: 10.5888/pcd16.190109.
6. KAGGLE. **kagglehub**: Python library to access Kaggle resources. [S. l.]: GitHub, [s. d.]. Disponível em: https://github.com/Kaggle/kagglehub. Acesso em: 8 nov. 2026.
7. GOOGLE. **Google Colaboratory**. [S. l.]: Google Research, [s. d.]. Disponível em: https://colab.research.google.com. Acesso em: 8 nov. 2026.
8. McKINNEY, W. Data structures for statistical computing in Python. In: PYTHON IN SCIENCE CONFERENCE, 9., 2010, Austin. **Proceedings** [...]. Austin: SciPy, 2010. p. 56–61. DOI: 10.25080/Majora-92bf1922-00a.
9. HARRIS, C. R. et al. Array programming with NumPy. **Nature**, London, v. 585, n. 7825, p. 357–362, 2020. DOI: 10.1038/s41586-020-2649-2.
10. HUNTER, J. D. Matplotlib: a 2D graphics environment. **Computing in Science & Engineering**, v. 9, n. 3, p. 90–95, 2007. DOI: 10.1109/MCSE.2007.55.
11. WASKOM, M. L. seaborn: statistical data visualization. **Journal of Open Source Software**, v. 6, n. 60, p. 3021, 2021. DOI: 10.21105/joss.03021.
12. PEDREGOSA, F. et al. Scikit-learn: machine learning in Python. **Journal of Machine Learning Research**, v. 12, n. 85, p. 2825–2830, 2011. Disponível em: https://jmlr.org/papers/v12/pedregosa11a.html. Acesso em: 21 out. 2026.
13. ABADI, M. et al. TensorFlow: a system for large-scale machine learning. In: USENIX SYMPOSIUM ON OPERATING SYSTEMS DESIGN AND IMPLEMENTATION (OSDI), 12., 2016, Savannah. **Proceedings** [...]. Berkeley: USENIX Association, 2016. p. 265–283.
14. CHOLLET, F. et al. **Keras**. [S. l.]: GitHub, 2015. Disponível em: https://keras.io. Acesso em: 21 out. 2026.
15. NAIR, V.; HINTON, G. E. Rectified linear units improve restricted Boltzmann machines. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING (ICML), 27., 2010, Haifa. **Proceedings** [...]. Madison: Omnipress, 2010. p. 807–814.
16. GLOROT, X.; BENGIO, Y. Understanding the difficulty of training deep feedforward neural networks. In: INTERNATIONAL CONFERENCE ON ARTIFICIAL INTELLIGENCE AND STATISTICS (AISTATS), 13., 2010, Sardinia. **Proceedings** [...]. [S. l.]: PMLR, 2010. v. 9, p. 249–256.
17. KINGMA, D. P.; BA, J. Adam: a method for stochastic optimization. In: INTERNATIONAL CONFERENCE ON LEARNING REPRESENTATIONS (ICLR), 3., 2015, San Diego. **Proceedings** [...]. [S. l.: s. n.], 2015. arXiv:1412.6980.
18. PRECHELT, L. Early stopping: but when? In: ORR, G. B.; MÜLLER, K.-R. (ed.). **Neural networks**: tricks of the trade. Berlin: Springer, 1998. p. 55–69. (Lecture Notes in Computer Science, 1524).
19. SRIVASTAVA, N.; HINTON, G.; KRIZHEVSKY, A.; SUTSKEVER, I.; SALAKHUTDINOV, R. Dropout: a simple way to prevent neural networks from overfitting. **Journal of Machine Learning Research**, v. 15, n. 56, p. 1929–1958, 2014.
20. KROGH, A.; HERTZ, J. A. A simple weight decay can improve generalization. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NIPS), 4., 1991, Denver. **Proceedings** [...]. San Mateo: Morgan Kaufmann, 1992. p. 950–957.

21. IOFFE, S.; SZEGEDY, C. Batch normalization: accelerating deep network training by reducing internal covariate shift. In: INTERNATIONAL CONFERENCE ON MACHINE LEARNING (ICML), 32., 2015, Lille. **Proceedings** [...]. [S. l.]: PMLR, 2015. v. 37, p. 448–456.

22. YOUDEN, W. J. Index for rating diagnostic tests. **Cancer**, v. 3, n. 1, p. 32–35, 1950.

23. BRIER, G. W. Verification of forecasts expressed in terms of probability. **Monthly Weather Review**, v. 78, n. 1, p. 1–3, 1950.

24. McFADDEN, D. Conditional logit analysis of qualitative choice behavior. In: ZAREMBKA, P. (ed.). **Frontiers in econometrics**. New York: Academic Press, 1974. p. 105–142.

25. TJUR, T. Coefficients of determination in logistic regression models: a new proposal: the coefficient of discrimination. **The American Statistician**, v. 63, n. 4, p. 366–372, 2009. DOI: 10.1198/tast.2009.08210.

26. KING, G.; ZENG, L. Logistic regression in rare events data. **Political Analysis**, v. 9, n. 2, p. 137–163, 2001. DOI: 10.1093/oxfordjournals.pan.a004868.

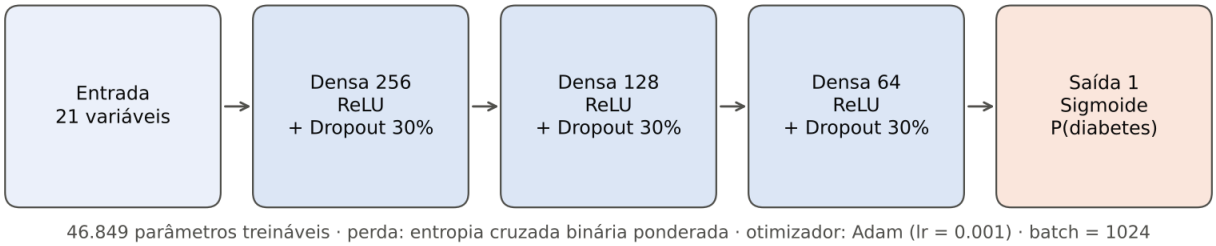
27. BREIMAN, L. Random forests. **Machine Learning**, v. 45, n. 1, p. 5–32, 2001. DOI: 10.1023/A:1010933404324.

28. LUNDBERG, S. M.; LEE, S.-I. A unified approach to interpreting model predictions. In: ADVANCES IN NEURAL INFORMATION PROCESSING SYSTEMS (NIPS), 30., 2017, Long Beach. **Proceedings** [...]. Red Hook: Curran Associates, 2017. p. 4765–4774.

29. HOSMER, D. W.; LEMESHOW, S.; STURDIVANT, R. X. **Applied logistic regression**. 3. ed. Hoboken: Wiley, 2013.

Apêndice A – Diagrama da arquitetura da rede neural

Figura 15 – Arquitetura da rede neural multicamadas (MLP) utilizada no trabalho



Fonte: elaborado pelos autores (2026), a partir do notebook do projeto.

Resumo da configuração final. 21 entradas → Densa 256 (ReLU) → Densa 128 (ReLU) → Densa 64 (ReLU) → 1 saída (sigmoide), com Dropout de 30% nas camadas ocultas; 46.849 parâmetros treináveis; entropia cruzada binária ponderada pelos pesos de classe; Adam (taxa de 0,001), lotes de 1.024 exemplos, Early Stopping com paciência de 8 épocas e restauração dos pesos da melhor época (época 13 de 21).